



PLANO DE EXECUÇÃO - PROJETO G2

Predição de Preços de Laptops

Disciplina: INF1032 - Introdução à Ciência de Dados

Professor: Adriano Branco

Instituição: PUC-Rio - Departamento de Informática

Turma: 3WA (Segunda e Quarta)

Equipe:

- Luis Felipe Gadelha (2210308)
- Victor Coutinho (2511084)
- Enzo Ferreira (2021641)

Dataset: Uncleaned Laptop Price Dataset (Kaggle)

Repositório: <https://github.com/lipegvgad/INF1032---Grupo01>

1. Definição do Problema

1.1 Descrição do Problema

O mercado de laptops apresenta alta variabilidade de preços (9.271 a 324.955 INR no dataset), dificultando a avaliação justa tanto para consumidores quanto para vendedores. Este projeto desenvolve um modelo preditivo de machine learning para estimar preços baseado em especificações técnicas.

1.2 Objetivo Principal

Desenvolver um modelo de regressão capaz de prever preços de laptops com MAE (Mean Absolute Error) inferior a 7.500 INR.

1.3 Resultado Alcançado

O melhor modelo (XGBoost com Log Transformation) atingiu MAE de 8.168,71 INR, ficando 668,71 INR (8,9%) acima do objetivo estabelecido.

1.4 Objetivos Secundários

- 1. Identificar e quantificar o impacto das principais características no preço - ATINGIDO
- 2. Realizar análise exploratória detalhada do mercado - ATINGIDO
- 3. Disponibilizar resultados interpretáveis via SHAP - ATINGIDO

1.5 Métricas de Avaliação

Métrica	Objetivo	Resultado	Status
MAE	< 7.500 INR	8.168,71 INR	Não atingido
R²	> 0.70	0.8432	Atingido
Melhoria vs Baseline	~80%	78,1%	Atingido

2. Escopo e Requisitos

2.1 Dataset

- Fonte: laptopData.csv (Kaggle - mercado indiano)
- Registros originais: 1.303 laptops
- Registros após tratamento: 1.273 (remoção de outliers > 200k INR)
- Variáveis originais: 12
- Features finais: 32 (após engenharia de features)

2.2 Variáveis Originais

Variável	Tipo	Descrição
Company	Categórica	Fabricante (21 marcas)
TypeName	Categórica	Categoria do laptop
Inches	Numérica	Tamanho da tela
ScreenResolution	Texto	Resolução e tipo de tela
Cpu	Texto	Processador completo
Ram	Numérica	Memória RAM (GB)
Memory	Texto	Armazenamento (SSD/HDD)
Gpu	Texto	Placa de vídeo
OpSys	Categórica	Sistema operacional
Weight	Numérica	Peso (kg)
Price	Numérica	Preço em INR (TARGET)

2.3 Limitações Identificadas

- Dataset pequeno: 1.273 amostras limitam generalização
- Mercado específico: Dados do mercado indiano apenas
- Heteroscedasticidade: Erro 3x maior em laptops premium (>100k INR)
- Concentração de features: Top 2 features explicam 84% do modelo

3. Etapas Executadas

3.1 Sprint 1 - Entendimento e EDA

- Análise exploratória completa do dataset
- Estatísticas descritivas: Preço médio 59.956 INR, mediana 50.990 INR
- Identificação de distribuição assimétrica positiva do preço
- Análise de correlações entre variáveis

3.2 Sprint 2 - Feature Engineering

Criação de 32 features a partir das 12 originais:

Features de CPU:

- Cpu_Speed: Velocidade extraída em GHz
- Cpu_Brand: Fabricante (Intel, AMD, etc.)

Features de GPU:

- Gpu_Brand: Fabricante (Intel, AMD, Nvidia)
- Gpu_Dedicated: Flag binária (0=integrada, 1=dedicada)

Features de Storage:

- SSD_GB, HDD_GB: Capacidades separadas
- Total_Storage: Soma total
- SSD_Ratio: Proporção SSD/Total

Features de Tela:

- Screen_Pixels: Resolução total calculada
- Is_Touchscreen, Is_IPS, Is_Retina: Flags binárias
- PPI: Pixels per inch

Features de Interação (15 adicionais):

- Multiplicativas: RAM_x_CPU_Speed, RAM_x_SSD, Storage_x_RAM
- Razões: SSD_Ratio, RAM_per_GHz
- Polinomiais: RAM², SSD², CPU_Speed²
- Indicadores: Premium_Config, Ultraportable, Gaming_Workstation

3.3 Sprints 3-4 - Modelagem

Modelos testados e resultados:

Modelo	MAE (INR)	R ²	Ranking
XGBoost (Log Transform)	8.168,71	0.8512	1º
XGBoost (GridSearch)	8.195	0.84	2º
XGBoost (Original)	8.275	0.83	3º
Random Forest (Inicial)	8.426	0.82	4º
Gradient Boosting	8.512	0.82	5º
RF (RandomizedSearch)	8.934	0.81	6º
Linear Regression	~11.500	0.72	7º

Técnica decisiva: Log Transformation do target (np.log1p) foi a otimização mais efetiva, reduzindo MAE de 8.275 para 8.168,71 INR.

3.4 Sprint 5 - Avaliação e SHAP

Análise SHAP implementada com 4 visualizações:

Feature Importance (Top 5):

1. RAM x SSD: 15,1%
2. RAM: 15,0%
3. RAM x CPU: 10,1%
4. Weight: 7,6%
5. SSD x CPU: 5,8%

Insight crítico: Top 2 features (RAM x SSD + RAM) explicam 30,1% do modelo, indicando alta concentração.

Análise de Erros por Faixa de Preço:

Faixa de Preço	MAE Médio	Amostras
Budget (<25k INR)	~5.000 INR	~30%
Entry (25-50k INR)	~6.500 INR	~35%
Mid (50-75k INR)	~8.500 INR	~20%
High (75-100k INR)	~12.000 INR	~10%
Premium (>100k INR)	~25.000 INR	~5%

4. Cronograma Executado

Marco	Data	Entrega	Status
M1	25/set	Sprint 1 - EDA Completo	Concluído
M2	02/out	G1 - Apresentação Inicial	Concluído
M3	14/out	Sprint 2 - Feature Engineering	Concluído
M4	28/out	Sprint 3 - Random Forest	Concluído
M5	06/nov	Sprint 4 - XGBoost + GridSearch	Concluído
M6	25/nov	Sprint 5 - Log Transform + SHAP	Concluído
M7	03/dez	G2 - Apresentação Final	Pendente

5. Análise de Riscos

Risco	Ocorreu?	Impacto	Mitigação
MAE > 7.500	SIM	Alto	Log Transform reduziu gap para 8,9%
Overfitting	Parcial	Médio	XGBoost regularizado
Dataset pequeno	SIM	Alto	Feature Engineering compensou
Membro ausente	NÃO	N/A	GitHub funcionou bem

6. Governança do Projeto

6.1 Equipe e Responsabilidades

Membro	Função	Entregas
Luis Felipe Gadelha	ML Lead	Modelagem, código
Victor Coutinho	Documentação	Relatórios, plano
Enzo Ferreira	Visualização	Gráficos, apresentação

6.2 Ferramentas Utilizadas

- Desenvolvimento: Google Colab (Python)
- Versionamento: GitHub (github.com/lipegvgad/INF1032---Grupo01)
- Comunicação: WhatsApp

- Bibliotecas principais: pandas, numpy, sklearn, xgboost, shap, matplotlib, seaborn

7. Conclusão e Aprendizados

7.1 Resultado Final

Objetivo parcialmente atingido. O modelo XGBoost com Log Transformation alcançou MAE de 8.168,71 INR, representando gap de 8,9% em relação ao objetivo de 7.500 INR. O R^2 de 0.8432 indica que o modelo explica 84,32% da variância dos preços.

7.2 Principais Aprendizados

1. Log Transformation foi a técnica mais efetiva para distribuições assimétricas de preço
2. Otimização de hiperparâmetros nem sempre melhora (RandomizedSearchCV piorou RF)
3. Feature Engineering teve mais impacto que model tuning
4. Heteroscedasticidade (erro variável por faixa de preço) é desafio não totalmente resolvido
5. SHAP analysis é essencial para interpretabilidade do modelo

7.3 Trabalhos Futuros

1. Coleta de dataset maior (5.000+ amostras)
2. Segmentação por faixa de preço (modelos específicos)
3. Ensemble Stacking (XGBoost + RF + LightGBM)
4. Validação em múltiplos mercados
5. Deploy como API (Flask/FastAPI)

7.4 Resumo Executivo

Este projeto desenvolveu um sistema de predição de preços de laptops utilizando técnicas de machine learning. Partindo de um dataset de 1.303 laptops com 12 variáveis, aplicamos feature engineering extensivo para criar 32 features, testamos 7 modelos diferentes e implementamos análise SHAP para interpretabilidade. O melhor resultado foi obtido com XGBoost + Log Transformation (MAE: 8.168,71 INR, R^2 : 0.8432), representando redução de 78,1% em relação ao baseline. Embora o objetivo de MAE < 7.500 INR não tenha sido plenamente atingido (gap de 8,9%), o projeto demonstrou aplicação completa do pipeline de ciência de dados e gerou insights valiosos sobre precificação no mercado de laptops.